Δομές Δεδομένων και Αρχείων

Κωνσταντίνος Κασφίκης 2013030108

Περιγραφή 'Ασκησης

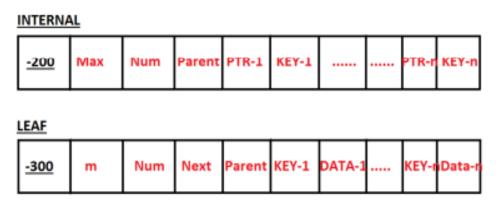
Στην συγκεκριμένη άσκηση ζητείται η υλοποίηση ενός B+ Tree στον δίσκο.Τα B+ Trees αποτελούν μια ιδιαίτερη μορφή B Trees η οποία επιτρέπει την αναζήτηση εύρους.

Όπως και τα B Trees τα B+ Trees αποτελούνται απο δύο ειδών κόμβους,τους εσωτερικούς και τα φύλλα. Οι εσωτερικοί κόμβοι (ή αλλιώς index) ουσιαστικά χρησιμεύουν στην ευκολότερη αναζήτηση δεδομένων, περιέχοντας ο καθένας μερικά από το σύνολο των κλειδιών. Έτσι, μέσω σύγκρισης του κάθε κλειδιού του εκάστοτε εσωτερικού κόμβου επιλέγεται ο κατάλληλος δείκτης προς το παρακάτω επίπεδο και διασχίζεται το δέντρο μέχρι να βρεθεί το φύλλο που περιέχει το κλειδί που μας ενδιαφέρει. Οι εσωτερικοί κόμβοι περιέχουν τόσο κλειδιά όσο και δείκτες σε παρακάτω κόμβους, ενώ τα φύλλα περιέχουν κλειδιά και δεδομένα. Ως βαθμός του B+ Tree (n) ορίζεται ο μέγιστος αριθμός δεικτών που μπορεί να περιέχει ένας εσωτερικός κόμβος.

Η περιγραφή της λειτουργίας του B+ Tree είναι η εξής: κατά την εισαγωγή του πρώτου κλειδιού δημιουργείται ένα φύλλο που λειτουργεί και ως ρίζα του δέντρου. Με την εισαγωγή n-1 στοιχείων στο δέντρο το φύλλο αυτό διχοτομείται σε 2 φύλλα και την θέση του καταλαμβάνει ένας εσωτερικός κόμβος ενός στοιχείου (συγκεκριμένα του n/2 στοιχείου που εισάχθηκε) που περιέχει 2 δείκτες (ο πρώτος στο πρώτο παραγόμενο φύλλο που περιέχει τα 1 μέχρι ((n/2)-1)-1 κλειδιά που εισήχθησαν, και ο άλλος στο δεύτερο παραγόμενο φύλλο που περιέχει τα κλειδία (n/2)-1 μέχρι n-1). Η εισαγωγή κλειδιών συνεχίζεται κανονικά εισάγωντας το εκάστοτε κλειδί στο κατάλληλο φύλλο και σχηματίζοντας παράλληλα τους κατάλληλους εσωτερικούς κόμβους μέχρι κάποιο φύλλο ή εσωτερικός κόμβος να γεμίσει οπότε πραγματοποιείται διχοτόμηση στον κόμβο αυτόν.

Μέρος 1°

Στον δίσκο, καθε φύλλο και κάθε εσωτερικός κόμβος στο παραγόμενο αρχείο έχουν την παρακάτω μορφή:



Όπου Num ο αριθμός που δείχνει πόσα ακριβώς κλειδιά περιέχει ο εκάστοτε κόμβος (δείχνει επίσης πόσα δεδομένα περιέχει ενα φύλλο και τον αριθμό των δεικτών ενός εσωτερικού κόμβου μειωμένο κατα 1), Parent δείκτης προς τον παραπάνω κόμβο του εκάστοτε κόμβου,ΚΕΥ1 έως ΚΕΥη τα κλειδιά που περιέχει ο κόμβος.Για τα φύλλα, m είναι ο αριθμός bytes που το κάθε δεδομένο κλειδιού καταλαμβάνει, Next είναι ο δείκτης στο επόμενο φύλλο (δεδομένο το οποίο επιτρέπει την αναζήτηση εύρους) και DATA1 έως DATAn τα δεδομένα m bytes που συνοδεύουν το κάθε κλειδί. Για τους εσωτερικούς κόμβους, Max είναι ο μέγιστος αριθμός κλειδιών, PTR έως PTRn είναι το σύνολο των δεικτών προς τους παρακάτω κόμβους (children) του κάθε εσωτερικου. Ο πρώτος ακέραιος του κάθε κόμβου(-200 ή -300) χρησιμοποιέιται για να διευκρινιστεί αν πρόκειται για φύλλο ή εσωτερικό κόμβο. Πολλές από τις παραπάνω βοηθητικές μεταβλητές των κόμβων χρησιμοποιούνται προκειμένου το αρχείο με το παραγόμενο δέντρο να μπορεί να τροποποιηθεί και εκτός του συγκεκριμένου προγράμματος(π.χ. m).

Για την υλοποίηση της άσκησης υπολογίζεται το η με τον εξής τρόπο:

n=((N-20)/m+4)+1

Όπου Ν το μέγεθος της σελίδας δίσκου, m το μέγεθος των δεδομενων σε byte που συνοδεύουν κάθε κλειδί. Ο υπολογισμός του n γίνεται με τρόπο τέτοιον ώστε ο αριθμός κλειδιών στους εσωτερικούς κόμβους να ισούται με τον αριθμό κλειδιών στα φύλλα. Τα 20 bytes που αφαιρούνται από το σύνολο των bytes της

σελίδας δίσκου αποτελούν τις βοηθητικές μεταβλητές για την "ανάγνωση" ή "εγγραφή" που κάθε κόμβος περιέχει.

Κανονικά το η θα έπρεπε να υπολογίζεται από τον εξής τύπο:

n=(N-20)/8

Όπου από το σύνολο των bytes της σελίδας αφαιρούνται 16 bytes που δεσμεύουν οι 4 πρώτοι ακέραιοι και 4 bytes του 1ου δείκτη. Ο παραγόμενος αριθμός διαιρείται με το 8 για τα ζέυγη των ακεραίων δεικτών-κλειδιών. Ωστόσο, ο παραπάνω τύπος δεν χρησιμοποιείται στην συγκεκριμένη υλοποίηση του B+ Tree γιατί τα φύλλα και οι εσωτερικοί κόμβοι θα είχαν διαφορετικό αριθμό κλειδιών, χρησιμοποιέιται ωστόσο μόνο για μέγεθος δεδομένων m=4bytes.

Στο ερώτημα αυτό πρεπεί να πραγματοποιηθεί η διαδικασία της εισαγωγής στο δέντρο, της αναζήτησης και της αναζήτησης εύρους.

Εισαγωγή:

Η εισαγωγή βασίζεται σε πολλές μεθόδους με βασικές την NonFullNode και την split που βρίσκονται στην κλάση BPlusTree. Η NonFullNode είναι η μέθοδος η οποία εισάγει το κάθε κλειδί στο κατάλληλο φύλλο, διασχίζοντας όλους τους εσωτερικούς κόμβους μέχρι να βρει το κατάλληλο φύλλο, ενώ η split διχοτομεί τους γεμάτους κόμβους δημιουργώντας έτσι τους εσωρερικούς κόμβους ή προσθέτοντας δείκτες σε αυτούς προς τους επιπλέον παραγόμενους κόμβους, αυξάνοντας κατά αυτόν τον τρόπο συνεχώς την "χωρητικότητα" του δέντρου. Η εισαγωγή τελικά γίνεται μέσω της μεθόδου insert της κλάσης BPlusTree.

Αναζήτηση:

Η αναζήτηση πραγματοποιείται με "είσοδο" ένα κλειδί του οποίου πρέπει να επιστραφούν τα δεδομένα (m bytes). Χρησιμοποιείται αναδρομική συνάρτηση (η οποία χρησιμοποιεί πολλές βοηθητικές μεθόδους) η οποία καλεί τον εαυτό της μέχρι να βρει φύλλο. Έτσι, κάθε φορά που καλείται η αναδρομική αυτή συνάρτηση αν ο κόμβος που εξετάζει είναι εσωτερικός ψάχνει τα κλειδιά αυτου μέχρι να βρει τον κατάλληλο δείκτη προς το παρακάτω επίπεδο, αλλιώς αν εξετάζει φύλλο ψάχνει τα κλειδιά αυτού μέχρι να βρει το ζητούμενο και επιστρέφει τα δεδομένα του. Η αναζήτηση πραγματοποιείται από την μέθοδο search της κλάσης BPlusTree.

Αναζήτηση Εύρους:

Η αναζήτηση εύρους πραγματοποιείται με "είσοδο" 2 κλειδιά, τα οποία δείχνουν την ελάχιστη και την μέγιστη τιμή του εύρους. Προκειμένου να υλοποιηθεί η αναζήτηση εύρους αρχικά καλείται η συνάρτηση getNodeLeafSearch η οποία επιστρέφει τον κόμβο στον οποίο βρίσκεται το κλειδί με την ελάχιστη τιμή. Με δεδομένο το αρχικό φύλλο που επέστρεψε η παραπάνω συνάρτηση η συνάρτηση rangeSearch διασχίζει τα φύλλα (χρησιμοποιώντας το Next που κάθε φύλλο περιέχει) μέχρι να βρει την μέγιστη τιμή του εύρους αναζήτησης η κάποια μεγαλύτερη τιμή. Η rangeSearch θα επιστρέψει τελικά εναν πίνακα τύπου Data (όπου Data είναι η κλάση στην οποία παράγονται και αποθηκεύονται τα δεδομένα του κάθε κλειδιού) με το σύνολο όλων των δεδομένων των κλειδιών που βρίσκονται μέσα στο εύρος αναζήτησης.

Η υλοποίση του προγράμματος γίνεται στον δίσκο. Έτσι για κάθε μία από τις παραπάνω λειτουργίες όσο και για την διαγραφή είναι απαραίτητη η μετατροπή συγκεκριμένων δεδομένων σε ακέραιους. Την διαδικασία αυτή πραγματοποιούν βοηθητικές συναρτήσεις (π.χ getChildNodes(), getNumKeys() κ.ο.κ). Επίσης, για την εγγραφή των δεδομένων του κάθε κόμβου χρησιμοποιούνται μέθοδοι οι οποίες μετατρέπουν τα στοιχεία απο ακέραιους σε bytes (integer=4bytes) και τα τοποθετούν στις κατάλληλες θέσεις σε κάθε κόμβο-σελίδα δίσκου (π.χ. writeInternal(), writeLeaf()) . Σημειώνεται επίσης ότι για την διευκόλυνση του χρήστη κάθε δεδομένο περιέχει στα τελευταία 4 bytes του έναν integer ίσο με τον κλειδί του, ενώ τα υπόλοιπα bytes έχουν παραχθεί τυχαία.

Στο πρώτο μέρος της άσκησης ζητείται να πραγματοποιηθούν η εισαγωγή κλειδίων από το 1-10⁵ και στην συνέχεια η αναζήτηση 20 τυχαίων κλειδιών στο δέντρο αυτό, μετρώντας ταυτόχρονα το μέσο όρο προσβάσεων στο δίσκο.Τέλος ζητείται η πραγματοποίση 20 αναζητήσεων εύρους και να μετρηθεί ο μέσος όρος προσβάσεων στο δίσκο.

Για N=1024, m=20 στις αναζητήσεις ο μέσος όρος προσβάσεων υπολογίζεται περίπου στο 3 ενώ στις αναζητήσεις εύρους υπολογίζεται στο 10.

Αναζήτηση:

The 37150 key has data [287205012] and the four last bytes of these data are (converted to integer):37050 and it was found with 3 disk accesses.

The 37505 key has data [287205012] and the four last bytes of these data are (converted to integer):27050 and it was found with 3 disk accesses.

The 37505 key has data [287205012] and the four last bytes of these data are (converted to integer):27050 and it was found with 3 disk accesses.

The 37505 key has data:[287205012] and the four last bytes of these data are (converted to integer):27050 and it was found with 3 disk accesses.

The 37505 key has data:[287205012] and the four last bytes of these data are (converted to integer):27050 and it was found with 3 disk accesses.

The 37507 key has data:[287405012] and the four last bytes of these data are (converted to integer):27050 and it was found with 3 disk accesses.

The 37507 key has data:[287405012] and the four last bytes of these data are (converted to integer):37050 and it was found with 3 disk accesses.

The 37507 key has data:[287405012] and the four last bytes of these data are (converted to integer):37100 and it was found with 3 disk accesses.

The 37507 key has data:[287060503] and the four last bytes of these data are (converted to integer):37100 and it was found with 3 disk accesses.

The 37507 key has data:[287060503] and the four last bytes of these data are (converted to integer):37103 and it was found with 3 disk accesses.

The 37507 key has data:[287060503] and the four last bytes of these data are (converted to integer):27103 and it was found with 3 disk accesses.

The 37508 key has data:[287060503] and the four last bytes of these data are (converted to integer):27103 and it was found with 3 disk accesses.

The 37508 key has data:[287060503] and the four last bytes of these data are (converted to integer):27103 and it was found with 3 disk accesses.

The 37508 key has data:[287060503] and the four last bytes of these data are (converted to integer):27103 and it was found with 3 disk accesses.

Αναζήτηση εύρους:

```
The 15426 key has data: [B%7692d9cc and the four last bytes of these data are (converted to integer):15426
The 15427 key has data: [B@75f32542 and the four last bytes of these data are(converted to integer):15427
The 15428 key has data: [887f1302d6 and the four last bytes of these data are (converted to integer):15428
The 15429 key has data: [B$43ee72e6 and the four last bytes of these data are (converted to integer):15429
The 15430 key has data: [B@23529fee and the four last bytes of these data are(converted to integer):15430
The 15431 key has data: [884fe767f3 and the four last bytes of these data are(converted to integer):15431
The 15432 key has data: [B@2805c96b and the four last bytes of these data are(converted to integer):15432
The 15433 key has data: [B@184cf7cf and the four last bytes of these data are(converted to integer):15433
The 15434 key has data: [B@2fd6b6c7 and the four last bytes of these data are(converted to integer):15434
The 15435 key has data: (B@5bfa9431 and the four last bytes of these data are (converted to integer): 15435
The 15436 key has data: [B@5db250b4 and the four last bytes of these data are (converted to integer): 15436
The 15437 key has data: [89223f3642 and the four last bytes of these data are(converted to integer):15437
The 15438 key has data: [B@38c5cc4c and the four last bytes of these data are(converted to integer):15438
The 15439 key has data: [B@37918c79 and the four last bytes of these data are(converted to integer):15439
The 15440 key has data; [B@78e94dof and the four last bytes of these data are (converted to integer): 15440
The 15441 key has data: [B@233fe9b6 and the four last bytes of these data are(converted to integer):15441
The 15442 key has data: [B@358ee631 and the four last bytes of these data are (converted to integer):15442
The 15443 key has data: [B@ec756bd and the four last bytes of these data are (converted to integer):15443
The 15444 key has data: [B@3c72f59f and the four last bytes of these data are(converted to integer):15444
The 15445 key has data: [B@60dcc9fe and the four last bytes of these data are(converted to integer):15445
The 15446 key has data: [80222114ba and the four last bytes of these data are (converted to integer):15446
The 15447 key has data: [B@16e7dofd and the four last bytes of these data are(converted to integer):15447
The 15448 key has data: [B@3d121db3 and the four last bytes of these data are(converted to integer):15448
The 15449 key has data: [B@3b07a0d6 and the four last bytes of these data are (converted to integer): 15449
The 15450 key has data: [B@11a9e7c8 and the four last bytes of these data are(converted to integer):15450
The 15451 key has data: [B@3901d134 and the four last bytes of these data are(converted to integer):15451
The 15452 key has data: [B@14d3bc22 and the four last bytes of these data are(converted to integer):15452
The 15453 key has data: [B@12d4bf7e and the four last bytes of these data are(converted to integer):15453
The 15454 key has data: [884cld9d4b and the four last bytes of these data are (converted to integer):15454
The 15455 key has data: [B@7b227d8d and the four last bytes of these data are (converted to integer):15455
The 15456 key has data: [B@7219ec67 and the four last bytes of these data are (converted to integer):15456
The 15457 key has data: [8845018215 and the four last bytes of these data are (converted to integer):15457
The 15458 key has data: [8865d6b83b and the four last bytes of these data are (converted to integer):15458
The 15459 key has data: [B@d706f19 and the four last bytes of these data are (converted to integer):15459
The 15460 key has data: [8030b7c004 and the four last bytes of these data are (converted to integer): 15460
The 15461 key has data: (B@79efed2d and the four last bytes of these data are (converted to integer):15461
The 15462 key has data: [B@2928854b and the four last bytes of these data are(converted to integer): 15462
The 15463 key has data: [8027ae2fd0 and the four last bytes of these data are (converted to integer): 15463
The 15464 key has data: [B@29176cc1 and the four last bytes of these data are(converted to integer):15464
The 15465 key has data: [B@2f177a4b and the four last bytes of these data are (converted to integer):15465
The 15466 key has data: [B@4278a03f and the four last bytes of these data are(converted to integer):15466
The 15467 key has data: [B8147ed70f and the four last bytes of these data are(converted to integer): 15467
The 15468 key has data: [B%61dd025 and the four last bytes of these data are (converted to integer):15468
```

The average number of disk accesses for the range search is: 10

Μέρος 2ο

Στο δεύτερο μέρος ζητείται η διαγραφή 20 τυχαίων κλειδίων από το δέντρο και ο υπολογισμός του μέσου όρου προσβάσεων στον δίσκο για την διαγραφή ενός στοιχείου.

Η διαγραφή πραγματοποιείται με την κλήση της μεθόδου delete της κλάσης BPlusTree. Υπάρχουν 2 διαφορετικές περιπτώσεις διαγραφής:

- 1) Διαγραφή μη πρώτου κλειδιού από φύλλο
- 2) Διαγραφή του πρώτου κλειδιού από φύλλο

Στην πρώτη περίπτωση πρέπει να διαγραφεί το κλειδί απο το φύλλο και στη συνέχεια να αλλάξει η τιμή του συγκεκριμένου κλειδιού στον πατέρα κόμβο (parent) στην τιμή του δεύτερου κλειδιού του φύλλου - έστω χ - (πριν την διαγραφή του πρωτου κλειδιού). Αν και στον πατέρα του πατέρα κόμβου το κλειδί αυτό είναι το πρώτο κλειδί τότε πρέπει να αλλάξει η τιμή του σε χ. Η διαδικασία αυτή επαναλαμβάνεται μέχρι να μην υπάρχει το κλειδί αυτό σε κανέναν κόμβο.

Στην δεύτερη περίπτωση η διαγραφή του κλειδιού απο το φύλλο αρκεί.

Η μέθοδος delete όπως και η μέθοδος rangeSearch καλεί την μέθοδο getNodeLeafSearch η οποία εντοπίζει το φύλλο στο οποίο είναι τοποθετημένα τα κλειδί που θέλουμε να διαγράψουμε και τα δεδομένα του. Στη συνέχεια η delete διαγράφει για κάθε περίπτωση το στοιχείο μειώνοντας παράλληλα κατά ένα τον αριθμό κλειδιών του επηρεαζόμενου κόμβου-φύλλο.

Ο μέσος όρος προσβάσεων στο δίσκο για την διαγραφή ενός στοιχείου υπολογίζεται στο 6.

							successiully		Irom	this	D+	tree	With	6	GISK	accesses.
The	50007	key	and	its	data	were	successfully	deleted	from	this	b+	tree	with	6	disk	accesses.
The	90331	key	and	its	data	were	successfully	deleted	from	this	b+	tree	with	6	disk	accesses.
The	71770	key	and	its	data	were	successfully	deleted	from	this	b+	tree	with	6	disk	accesses.
The	36924	key	and	its	data	were	successfully	deleted	from	this	b+	tree	with	6	disk	accesses.
The	12795	key	and	its	data	were	successfully	deleted	from	this	b+	tree	with	6	disk	accesses.
The	56543	key	and	its	data	were	successfully	deleted	from	this	b+	tree	with	6	disk	accesses.
The	17518	key	and	ita	data	were	successfully	deleted	from	this	b+	tree	with	6	disk	accesses.
The	22965	key	and	its	data	were	successfully	deleted	from	this	b+	tree	with	6	disk	accesses.
The	74129	key	and	its	data	were	successfully	deleted	from	this	b+	tree	with	6	disk	accesses.
The	95804	key	and	its	data	were	successfully	deleted	from	this	b+	tree	with	6	disk	accesses.
The	34994	key	and	its	data	were	successfully	deleted	from	this	b+	tree	with	6	disk	accesses.
The	81406	key	and	its	data	were	successfully	deleted	from	this	b+	tree	with	6	disk	accesses.
the	16308	key	and	ita	data	were	successfully	deleted	from	this	b+	tree	with	6	disk	accesses.
The	49692	key	and	its	data	were	successfully	deleted	from	this	b+	tree	with	6	disk	accesses.
27.7		70,77-3			7,755		sses for dele									

(Bonus) Μέρος 3ο

Γίνονται μετρήσεις για N=1024 και m=20.

Ο μέσος όρος προσβάσεων στον δίσκο για:

Αναζήτηση: 3

Αναζήτηση Εύρους: 10

Διαγραφή: 6

Επαναλαμβάνονται οι ίδιες μετρήσεις για N=1024 και m=50

Ο μέσος όρος προσβάσεων στον δίσκο για:

Αναζήτηση: 2

Αναζήτηση Εύρους: 8

Διαγραφή: 5

Η διαφορά ανάμεσα στο σύνολο των μετρήσεων για διαφορετικά m οφείλεται στο γεγονός ότι με την υλοποίηση του συγκεκριμένου B+ Tree το m είναι αντιστρόφως ανάλογο του n (και επομένως του μέγιστου αριθμού κλειδιών που ένας κόμβος μπορεί να περιέχει). Όσο μικρότερο είναι το m τόσο περισσότερα κλειδιά χωράνε σε έναν κόμβο. Εφόσον αυξάνεται ο αριθμός των κλειδιών του κάθε κόμβου, μειώνεται ο αριθμός των φύλλων και των εσωτερικών κόμβων του δέντρου με αποτέλεσμα οι εύρεση του φύλλου με το κλειδί που μας ενδιαφέρει να γίνεται διασχίζοντας λιγότερους εσωτερικούς κόμβους. Ο παραπάνω παράγοντας αφορά όλες τις λειτουργίες του προγράμματος. Ωστόσο η αναζήτηση εύρους με μικρότερο m επηρεάζεται και από το γεγονός ότι τα φύλλα περιέχουν περισσότερα κλειδιά και επομένως δεδομένα, με αποτέλεσμα να μεταφέρονται σε λιγότερα επόμενα φύλλα.

Μετά από την υλοποίηση των παραπάνω μετρήσεων το πρόγραμμα μεταβαίνει σε ένα menu που δίνει στον χρήστη την δυνατότητα να εισάγει, διαγράψει και να αναζητήσει κλειδιά. Του δίνεται ακόμα να δημιουργήσει B+ Tree με N,m που ο ίδιος θα καθορίσει.

Το πρόγραμμα υλοποιήθηκε σε γλώσσα προγραμματισμού JAVA σε περιβάλλον Eclipse για Windows.